


Dynamic Mode Decomposition 入門ノート

岡田崇 Takashi Okada



目次

このノートの目的	2
1 因果関係とは	2
2 Dynamic Mode Decomposition	3
2.1 基本的な考え方	3
2.2 データ行列を作る	4
2.3 なぜ pseudo-inverse の問題に帰着するのか	4
2.4 なぜ pseudo-inverse が問題になるのか	10
2.5 DMD モードと固有値の意味	10
3 実務的には	11
3.1 Bootstrapping	11
3.2 Regularization	11
3.3 実務でのチェックポイント	12
4 発展的な内容	13
4.1 Kalman Filter	13
4.2 Koopman Operator	13
4.3 Sparse Identification of Nonlinear Dynamics, SINDy	14
5 まとめ	15
参考文献	16

このノートの目的

このノートでは、Dynamic Mode Decomposition、略して DMD を初学者向けに説明する。特に次の流れを重視する。

1. 因果関係と同時相関の違いを確認する。
2. DMD を「線形の力学系を仮定した最小二乗問題」として理解する。
3. 実務で重要になる Bootstrapping と Regularization を整理する。
4. Kalman Filter、Koopman Operator、SINDy との関係を概観する。

本ノートのキーワード. DMD の中心的な考え方は、時系列データから

$$x_{t+1} \approx Ax_t$$

という線形の時間発展を推定することである。複雑な現象を、まずは「1 ステップ先へ進める行列」 A で近似する。

1 因果関係とは

データ分析で最初に注意したいのは、**相関があることと、因果関係があることは違う**という点である。

たとえば、2 つの時系列 x_t と y_t があり、同じ時刻 t において強く相関していたとする。

$$\text{corr}(x_t, y_t) \text{ が大きい}$$

しかし、これだけでは次のどれが起きているのか分からない。

- x が y の原因になっている。
- y が x の原因になっている。
- 第三の変数 z が x と y の両方を動かしている。
- 季節性、トレンド、周期性などによって、たまたま同じように動いている。
- 因果効果はあるが、同時刻ではなく遅れて現れている。

注意

同時相関だけでは因果関係は分からない。

x_t と y_t が同時に動いていても、どちらがどちらを動かしたのか、あるいは別の変数が両方を

動かしたのかは判断できない。

特に時系列データでは、同時刻の相関だけを見ると危険である。原因は結果より前に起きる必要があるため、少なくとも時間順序を考える必要がある。

因果を議論するには、少なくとも次の視点が重要になる。

1. **時間順序** 原因は結果より前に起きる必要がある。
2. **交絡の考慮** 第三の変数が両方を動かしていないかを確認する必要がある。
3. **介入または仮定** 「もし x を外から変えたら y は変わるか」という視点が重要になる。

DMD は、基本的には因果推論の手法ではない。DMD が推定するのは

$$x_{t+1} \approx Ax_t$$

という形の時間発展モデルである。したがって、DMD で得られる行列 A は「現在の状態から次の状態をどう予測するか」を表すものであり、そのまま因果グラフや因果効果と解釈してはいけない。

補足. DMD は同時相関だけではなく、時間の前後関係を使う。そのため、単なる相関分析よりも「ダイナミクス」を見る分析になっている。ただし、DMD の結果をそのまま因果関係と解釈するのは危険である。

2 Dynamic Mode Decomposition

2.1 基本的な考え方

DMD は、時系列データから次のような線形の力学系を推定する方法である。

基本式

$$x_{t+1} \approx Ax_t$$

ここで、 x_t は時刻 t における状態ベクトル、 A は状態を 1 ステップ先に進める線形写像である。たとえば、気温、圧力、速度場、売上、センサー値などをまとめたベクトルを x_t と考える。DMD では、これらが次の時刻にどう変化するかを、できるだけ線形写像 A で説明しようとする。

重要な仮定は次である。

この仮定を言い換えると、

次の状態 $\approx$ 現在の状態に行列 A をかけたもの

である。DMD は、複雑な現象をまず線形モデルで近似する方法である。

2.2 データ行列を作る

時系列データとして、次のスナップショットが得られているとする。

$$x_1, x_2, x_3, \dots, x_m$$

各 x_i はベクトルである。DMD では、現在の状態を並べた行列 X と、1 ステップ後の状態を並べた行列 X' を作る。

$$X = \begin{bmatrix} | & | & & | \\ x_1 & x_2 & \cdots & x_{m-1} \\ | & | & & | \end{bmatrix}, \quad X' = \begin{bmatrix} | & | & & | \\ x_2 & x_3 & \cdots & x_m \\ | & | & & | \end{bmatrix}.$$

DMD の目標は、次を満たすような行列 A を見つけることである。

$$X' \approx AX.$$

2.3 なぜ pseudo-inverse の問題に帰着するのか

ここでは、DMD の中心式

$$A = X'X^+$$

がなぜ現れるのかを、二つの見方から導出する。

1. **最小二乗を直接解く見方** 誤差を最小にする条件から、通常の逆行列の代わりに疑似逆行列が現れることを見る。
2. **疑似逆行列を SVD で見る見方** データで説明できる方向だけを反転し、説明できない方向は無理に反転しない、という直感から理解する。

どちらも同じ結論

$$A = X'X^+$$

に到達する。前者は計算の導出、後者は疑似逆行列の意味を理解するための導出である。

2.3.1 まず、DMD で本当にやりたいこと

DMD の出発点は、隣り合う時刻のデータが

$$x_{k+1} \approx Ax_k$$

で結ばれている、という仮定である。

ここで重要なのは、**すべての時刻で同じ行列 A を使う**という点である。つまり、時刻ごとに別々のルールを作るのではなく、

$$x_1 \mapsto x_2, \quad x_2 \mapsto x_3, \quad \dots, \quad x_{m-1} \mapsto x_m$$

というすべての変化を、できるだけ同じ行列 A で説明したい。

そのために、現在側のデータを

$$X = \begin{bmatrix} | & | & \cdots & | \\ x_1 & x_2 & \cdots & x_{m-1} \\ | & | & \cdots & | \end{bmatrix},$$

1 ステップ後のデータを

$$X' = \begin{bmatrix} | & | & \cdots & | \\ x_2 & x_3 & \cdots & x_m \\ | & | & \cdots & | \end{bmatrix}$$

と置く。すると、すべての関係式はまとめて

$$X' \approx AX$$

と書ける。

DMD の推定問題

DMD では、同じ行列 A によって

$$X' \approx AX$$

をできるだけよく満たすようにする。したがって、基本問題は

$$\min_A \|X' - AX\|_F^2$$

である。ここで $\|\cdot\|_F$ は行列の全成分の二乗和を測るノルムであり、各時刻の予測誤差を全部足したものだと思えばよい。

2.3.2 もし普通の逆行列が使えたら

まず理想的な場合を考える。もし

$$X' = AX$$

が完全に成り立ち、さらに X が正方行列で逆行列 X^{-1} を持つなら、右から X^{-1} をかけて

$$A = X'X^{-1}$$

と求められる。

つまり、DMD でやりたいことは本質的には

「現在側のデータ X を使って、次側のデータ X' を説明する」

ことである。通常の逆行列が使えるなら話は簡単である。

しかし現実には、 X はたいてい正方行列ではない。状態の次元を n 、時間遷移の数を $N = m - 1$ とすると、

$$X \in \mathbb{R}^{n \times N}$$

である。変数の数 n とデータ数 N は一般に一致しない。また、一致したとしても、ノイズやデータの重複によって X がフルランクとは限らない。

したがって、普通の逆行列 X^{-1} は使えない。そこで、逆行列の代わりに **Moore–Penrose 疑似逆行列** X^+ を使う。

2.3.3 導出 1: 最小二乗を直接解く

DMD では、完全に

$$X' = AX$$

を満たす A を探すのではなく、誤差が平均的に小さくなる A を探す。そこで、目的関数を

$$J(A) = \frac{1}{2} \|X' - AX\|_F^2$$

と置く。係数 $1/2$ は、微分したときに式を見やすくするためのもので、本質的な意味はない。

まず 1 変数の最小二乗を思い出す。 $y \approx ax$ を一番よく満たす a を選ぶとき、最小値では

$$(ax - y)x = 0$$

という条件が出てくる。これは、残った誤差 $ax - y$ が、説明に使ったデータ x の方向にこれ以上残っていない、という意味である。

行列の場合も考え方は同じである。残差を

$$R = AX - X'$$

と置くと、最小値ではこの残差が、説明に使ったデータ X の方向に残らない。これを式で書くと

$$RX^\top = 0$$

である。つまり

$$(AX - X')X^\top = 0$$

となる。整理すると

$$AXX^\top = X'X^\top$$

を得る。この式は「最小二乗解が満たす条件」である。線形代数では**正規方程式 (normal equations)**と呼ばれる。意味としては、**最小二乗では、残差が説明変数の方向と直交する**ということである。

もし $XX^\top$ が逆行列を持つなら、右から $(XX^\top)^{-1}$ をかけて

$$A = X'X^\top (XX^\top)^{-1}$$

となる。

ここで、 X が行フルランクである場合、Moore–Penrose 疑似逆行列は

$$X^+ = X^\top (XX^\top)^{-1}$$

と書ける。したがって、

$$A = X'X^+$$

となる。

より一般に、 $XX^\top$ が逆行列を持たない場合や、 X が行フルランクでない場合でも、Moore–Penrose 疑似逆行列を使うことで

$$A = X'X^+$$

と書ける。この A は

$$\min_A \|X' - AX\|_F^2$$

の標準的な最小二乗解である。解が一意に決まらない場合には、同じ予測誤差を与える A が複数存在しうが、 $X'X^+$ はその中で余計な大きさを持たない、最小ノルムの代表解を選ぶ。

2.3.4 導出 2: 疑似逆行列の直感: 係数を探してから次へ進める

疑似逆行列を使う理由は、次の見方をすると分かりやすい。

ある状態 z が与えられたとする。この z を、観測された現在側のスナップショット $x_1, \dots, x_{m-1}$ の線形結合で表したい。

$$z \approx Xc$$

ここで c は係数ベクトルである。

もし $z \approx Xc$ と書けたなら、「同じ係数 c を次側のスナップショットに使う」と考えるのが自然である。つまり、

$$z \approx Xc \implies \text{次の状態} \approx X'c$$

とする。

問題は、係数 c が一意に決まるとは限らないことである。

- データが足りないと、完全には $z = Xc$ と書けないことがある。
- データが多すぎたり重複していたりすると、同じ z を表す c が複数あることがある。

このとき、疑似逆行列は

$$c = X^+z$$

という形で、**最小二乗の意味で最も自然な係数**を選ぶ。完全に表せない場合は一番近い表現を選び、複数の表現がある場合は余計な大きさを持たない最小ノルムの係数を選ぶ。

したがって、状態 z を 1 ステップ進める写像は

$$z \mapsto X'c = X'X^+z$$

と書ける。任意の z に対してこの形で作用するので、DMD の行列は

$$A = X'X^+$$

となる。

疑似逆行列が出る理由

DMD では、まず現在の状態を

$$z \approx Xc$$

とデータの線形結合で表し、その同じ係数を使って

$$\text{次の状態} \approx X'c$$

と予測する。係数 c を最小二乗の意味で選ぶ写像が X^+ なので、

$$A = X'X^+$$

が自然に現れる。

2.3.5 導出 2 の補足: SVD で見る導出

少しだけ線形代数を使うと、なぜ X^+ が最小二乗解を与えるのかも見通しよく分かる。 X のランクを r とし、コンパクト SVD を

$$X = U_r \Sigma_r V_r^\top$$

と書く。ここで、 Σ_r はゼロでない特異値だけを並べた対角行列である。

この分解は、 X が次の三つの操作からできていると考えられる。

1. $V_r^\top$ によって、データの時間方向の主要な成分を取り出す。
2. Σ_r によって、それぞれの成分を特異値だけ伸ばす。
3. U_r によって、状態空間の方向に戻す。

逆向きにたどるなら、順番を逆にして、伸ばした分を $1/\sigma_i$ で割ればよい。したがって、疑似逆行列は

$$X^+ = V_r \Sigma_r^{-1} U_r^\top$$

となる。

ここでゼロ特異値に対応する方向は、データに情報がない方向である。その方向では割り算ができないので、疑似逆行列では無理に逆を作らず、その成分を捨てる。これが通常の逆行列との違いである。

DMD の問題

$$\min_A \|X' - AX\|_F^2$$

に $X = U_r \Sigma_r V_r^\top$ を代入すると、

$$AX = AU_r \Sigma_r V_r^\top$$

である。つまり、データが実際に持っている方向 U_r 上での A の働きだけが、予測 AX に影響する。

そこで

$$B = AU_r$$

と置けば、予測は

$$AX = B\Sigma_r V_r^\top$$

と書ける。最もよく X' に合うようにするには、データが持っている時間方向 V_r 上で

$$B\Sigma_r \approx X'V_r$$

とすればよい。 Σ_r はゼロでない特異値だけを持つので逆行列があり、

$$B = X'V_r\Sigma_r^{-1}$$

と求まる。

最後に、 $B = AU_r$ だったので、データが張る方向 U_r 上では

$$A \approx BU_r^\top$$

とすればよい。データに現れない方向については何も情報がないため、Moore–Penrose 疑似逆行列はその部分を余計に動かさない、最も小さいノルムの選び方をする。したがって

$$A = X'V_r\Sigma_r^{-1}U_r^\top = X'X^+$$

となる。

ここまでのまとめ

DMD の基本計算は、次の流れで理解できる。

$$x_{k+1} \approx Ax_k \implies X' \approx AX \implies \min_A \|X' - AX\|_F^2 \implies A = X'X^+.$$

疑似逆行列 X^+ は、普通の逆行列が使えないときに、データで説明できる範囲だけを反転し、説明できない方向は無理に反転しないための道具である。

2.3.6 小さい特異値があると不安定になる

SVD 表示

$$X^+ = V_r\Sigma_r^{-1}U_r^\top$$

を見ると、疑似逆行列の危険性も分かる。 Σ_r^{-1} では、特異値 σ_i を

$$\frac{1}{\sigma_i}$$

に置き換える。したがって、非常に小さい特異値があると、その逆数は非常に大きくなる。

これは、データの中ではほとんど見えていない方向を、無理に大きく引き伸ばすことを意味する。そのため、小さなノイズが推定された A の中で大きく増幅されることがある。

この理由から、実務では小さい特異値をすべて使うのではなく、重要な特異値だけを残す低ランク近似や、Ridge 正則化などを使うことが多い。

2.4 なぜ pseudo-inverse が問題になるのか

現実のデータでは、 X がきれいに逆行列を持つとは限らない。理由はいくつかある。

- 変数の数が多い。
- サンプル数が少ない。
- ノイズがある。
- 似たような変数が多く、行列がほぼ特異になる。
- 小さい特異値が存在し、数値的に不安定になる。

通常の逆行列 X^{-1} が使えない場合でも、疑似逆行列 X^+ を使えば最小二乗解を計算できる。ただし、小さい特異値をそのまま反転すると、ノイズが大きく増幅されることがある。

注意

DMD を実務で使うときの大きな問題は、疑似逆行列がノイズを増幅しやすいことである。特に小さい特異値を反転すると、推定された A が不安定になりやすい。

そのため、DMD ではしばしば SVD による低ランク近似や正則化を使う。

2.5 DMD モードと固有値の意味

推定した行列 A の固有値・固有ベクトルを見ると、システムの時間発展を分解できる。

$$A\phi_j = \lambda_j\phi_j.$$

ここで、 ϕ_j は DMD モード、 λ_j は DMD 固有値である。

ざっくり言うと、DMD モード ϕ_j は「空間的なパターン」、固有値 λ_j は「そのパターンが時間とともにどう変化するか」を表す。

条件	解釈
$ \lambda_j > 1$	そのモードは成長する。
$ \lambda_j < 1$	そのモードは減衰する。
$ \lambda_j \approx 1$	そのモードは持続しやすい。
λ_j が複素数	振動や周期性を表す。

見方. DMD は、複雑な時系列を「成長・減衰・振動するパターンの足し合わせ」として理解する

方法だと考えると分かりやすい。

3 実務的には

実務で DMD を使うときは、単に

$$A = X'X^+$$

を計算するだけでは不十分なことが多い。現実のデータには、ノイズ、外れ値、サンプル不足、モデルのミスマッチがあるからである。

そこで重要になるのが、Bootstrapping と Regularization である。

3.1 Bootstrapping

Bootstrapping は、データを再サンプリングして同じ分析を何度も行う方法である。DMD では、たとえば次のように使う。

1. 元の時系列データから複数のサンプルを作る。
2. それぞれに対して DMD を実行する。
3. 得られた固有値、モード、予測結果のばらつきを見る。

これにより、次のようなことが分かる。

- ある DMD モードが安定して出てくるか。
- 固有値の推定がどれくらい不確かか。
- 予測結果にどれくらい幅があるか。
- ノイズやサンプルの取り方に敏感すぎないか。

実務メモ. Bootstrapping の目的は、単に 1 つの答えを出すことではない。その答えがどれくらい安定しているか、どれくらい信用できるかを見ることである。

特に時系列データでは、データ点を完全にランダムにシャッフルすると時間構造が壊れることがある。そのため、連続した時間区間をまとめて再サンプリングする block bootstrap のような考え方が使われることもある。

3.2 Regularization

Regularization、つまり正則化は、過学習や数値的不安定性を抑えるための工夫である。

DMD では、疑似逆行列を計算するときに小さい特異値が問題になる。小さい特異値を反転すると、ノイズが大きく増幅される。そこで、代表的には次のような方法を使う。

3.2.1 低ランク近似

SVD を使って、重要な成分だけを残す。

$$X \approx U_r \Sigma_r V_r^T.$$

ここで r は残すランクである。小さい特異値に対応する成分を捨てることで、ノイズの影響を減らす。

実務メモ. DMD における最も基本的な正則化の一つは、SVD による低ランク近似である。ランクを大きくしすぎるとノイズを拾い、小さくしすぎると重要な構造を捨てる。

3.2.2 Ridge 正則化

最小二乗問題にペナルティを加える。

$$\min_A \|X' - AX\|_F^2 + \alpha \|A\|_F^2.$$

ここで $\alpha > 0$ は正則化の強さである。 α が大きいほど、行列 A が過度に大きくなることを防ぐ。

3.2.3 Sparse 正則化

場合によっては、行列 A の多くの要素がゼロに近いと仮定することもある。これは「少数の重要な相互作用だけがある」と考える場合に有効である。

ただし、スパース性を入れると解釈しやすくなる一方で、モデルの仮定も強くなる。

3.3 実務でのチェックポイント

DMD を実務で使うときは、次の 5 点を確認するとよい。

1. データの前処理: トレンド、季節性、スケールの違いをどう扱うか。
2. ランクの選択: 何個のモードを残すか。
3. 予測性能: 学習に使っていない期間で予測が合うか。
4. モードの安定性: Bootstrapping しても同じようなモードが出るか。
5. 解釈の慎重さ: DMD の A は予測モデルであり、ただちに因果関係を意味しない。

4 発展的な内容

ここでは、DMD の周辺にある重要な考え方を簡単に紹介する。

4.1 Kalman Filter

Kalman Filter は、状態空間モデルに基づく推定手法である。DMD では基本的に

$$x_{t+1} = Ax_t$$

のような決定論的なモデルを考える。一方、Kalman Filter では

$$x_{t+1} = Ax_t + w_t, \quad y_t = Cx_t + v_t$$

のように書く。

ここで、 x_t は真の状態、 y_t は観測値、 w_t はプロセスノイズ、 v_t は観測ノイズ、 C は状態から観測への写像である。

発展メモ. Kalman Filter は、**確率過程と観測誤差を考慮できる**。DMD で推定した A を状態遷移行列として使い、Kalman Filter でノイズを考慮した状態推定を行う、という考え方もできる。

現実には、私たちが観測しているデータは真の状態そのものではないことが多い。センサー誤差、欠測、外乱などがある。Kalman Filter は「モデルからの予測」と「実際の観測による修正」を繰り返す方法である。

4.2 Koopman Operator

DMD を少し深く理解するには、Koopman Operator の考え方が重要になる。

通常、非線形の力学系は

$$x_{t+1} = F(x_t)$$

のように書かれる。ここで F は非線形な関数である。

Koopman Operator の考え方では、状態 x そのものではなく、状態を観測する関数 $g(x)$ に注目する。たとえば、 $g(x) = x$ だけでなく、 $g(x) = x^2$ 、 $g(x) = \sin x$ 、 $g(x) = x_1 x_2$ のような観測量を考える。

Koopman Operator は、観測量の時間発展を表す作用素である。

$$(Kg)(x) = g(F(x)).$$

発展メモ. 元の力学系 F が非線形でも、Koopman Operator K は線形作用素になる。ただし、その代わりに、通常は無限次元の関数空間を考える必要がある。

DMD は、この Koopman Operator を有限次元で近似していると見ることができる。つまり、DMD は単なる線形回帰としても理解できるが、より深くは「非線形力学系を、観測量の空間で線形に見る方法」とも理解できる。

この考え方を拡張したものに Extended DMD、略して EDMD がある。EDMD では、状態 x だけでなく、さまざまな特徴量や基底関数を使って、より豊かな空間で線形モデルを作る。

4.3 Sparse Identification of Nonlinear Dynamics, SINDy

SINDy は、非線形力学系の支配方程式をデータから発見する方法である。

DMD が基本的に

$$x_{t+1} \approx Ax_t$$

という線形モデルを仮定するのに対して、SINDy では

$$\frac{dx}{dt} = f(x)$$

の形の非線形方程式を探す。

ただし、完全に自由な非線形関数 f を探すのは難しい。そこで SINDy では、候補となる関数をあらかじめたくさん用意する。たとえば、 1 、 x 、 x^2 、 x^3 、 $\sin x$ 、 $\cos x$ などである。

そして、

$$\frac{dx}{dt} \approx \Theta(x)\xi$$

と書く。ここで、 $\Theta(x)$ は候補関数を並べたライブラリ、 ξ は各候補関数の係数である。

発展メモ. SINDy の重要な仮定は、**本当に必要な項は少数である**ということである。多くの候補関数の中から、重要なものだけをスパース回帰で選ぶ。

DMD と SINDy の違いは次のように整理できる。

手法	基本仮定	得られるもの
DMD	状態は線形写像で進む	線形時間発展行列、モード、固有値
SINDy	支配方程式は少数の項で書ける	非線形の微分方程式

SINDy は解釈しやすい方程式を得られる可能性がある一方で、微分の推定やノイズの影響に注意が必要である。

5 まとめ

DMD は、時系列データから

$$x_{t+1} \approx Ax_t$$

という線形の力学系を推定する方法である。基本的には

$$X' \approx AX$$

という最小二乗問題であり、その解は

$$A = X'X^+$$

と疑似逆行列を使って書ける。

重要

DMD は、時系列データから線形の時間発展を最小二乗で推定する方法である。

ただし、実データではノイズやサンプル不足により、疑似逆行列の計算が不安定になりやすい。そのため、低ランク近似、Ridge 正則化、Bootstrapping などが重要になる。

また、DMD は因果推論の手法ではない。同時相関だけを見るよりは時間構造を使っているが、DMD で得られた行列をそのまま因果関係と解釈するのは危険である。

発展的には、Kalman Filter、Koopman Operator、SINDy が DMD と関連している。

- **Kalman Filter:** 確率過程と観測誤差を考慮した状態推定。
- **Koopman Operator:** 非線形力学系を観測量の空間で線形に見る理論。
- **SINDy:** スパース回帰によって非線形支配方程式を発見する方法。

参考文献

- [1] P. J. Schmid, “Dynamic mode decomposition of numerical and experimental data,” *Journal of Fluid Mechanics*, 656, 5–28, 2010.
- [2] J. H. Tu, C. W. Rowley, D. M. Luchtenburg, S. L. Brunton, and J. N. Kutz, “On dynamic mode decomposition: theory and applications,” *Journal of Computational Dynamics*, 1(2), 391–421, 2014.
- [3] B. O. Koopman, “Hamiltonian systems and transformation in Hilbert space,” *Proceedings of the National Academy of Sciences*, 17(5), 315–318, 1931.
- [4] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Journal of Basic Engineering*, 82(1), 35–45, 1960.
- [5] S. L. Brunton, J. L. Proctor, and J. N. Kutz, “Discovering governing equations from data by sparse identification of nonlinear dynamical systems,” *Proceedings of the National Academy of Sciences*, 113(15), 3932–3937, 2016.